

NOVENO LABORATORIO

Uno de los problemas clásicos de la humanidad es la predicción de Series Temporales (ST). Desde muy antiguo el hombre ha intentado predecir el futuro (y no nos referimos a bolas de cristal o cartas del tarot) mediante métodos matemáticos basados en la observación. Así Thales de Mileto fue capaz de predecir un eclipse de Sol en el siglo VI a.C y los egipcios eran capaces de predecir las cosechas (y los impuestos correspondientes) con el *Nilómetro*. Busque información sobre ambas predicciones en su IA favorita.

En la actualidad la predicción de ST es una de las ramas de la IA más popular en áreas como economía, medicina, industria, medio ambiente y en casi todas las actividades humanas.


En general, el problema de la predicción de ST no es más que un problema de regresión (vea los laboratorios 1, 2 y 3). Veamos por qué:

Una ST es un listado de valores numéricos tomados a intervalos regulares. Por ejemplo, de hora en hora:

Fecha y Hora de observación	Resultados Observados
2024-01-01 00:00:00	109,3189622
2024-01-01 01:00:00	111,3579610
2024-01-01 02:00:00	132,5210655
2024-01-01 03:00:00	124,1892154
2024-01-01 04:00:00	125,7010677
2024-01-01 05:00:00	134,3159199
2024-01-01 06:00:00	¿A?
2024-01-01 07:00:00	¿B?

Esta serie se puede transformar en un *dataset* de regresión así:

Lag-2	Lag-1	Resultados esperados
109,3189622	111,3579610	132,5210655
111,3579610	132,5210655	124,1892154
132,5210655	124,1892154	125,7010677



124,1892154	125,7010677	134,3159199
125,7010677	134,3159199	¿A?
134,3159199	A	¿B?


En este caso se ha tomado un pasado de 2 unidades (Past History, PH=2) de forma que cada momento “ t ” el valor esperado se predice en función de los valores observados en los dos momentos inmediatamente anteriores. Cada valor así creado se llama *Lag* (retraso o desfase en español): *Lag-1* para la hora anterior $t-1$, *Lag-2* para dos horas antes o $t-2$, y así sucesivamente.

Los valores históricos nos sirven para aprender (entrenar) el modelo de regresión que, aplicado a los dos últimos valores, proporcionará el pronóstico para las 6 de la mañana (A). Si se quisiera predecir más de un valor se añade la predicción de A (**ATENCIÓN la predicción, NO el valor real**) a la siguiente fila para predecir B con el mismo modelo. A esta técnica se le denomina “**Ventana Deslizante**”. El número de pasos a predecir se llama “*horizonte de predicción*” (FH por sus siglas en inglés).

El parámetro FH debe ser proporcionado a priori, y el PH debe ser ajustado en la fase de entrenamiento para reducir el error de predicción, normalmente *MAE* o *MSE* (vea los laboratorios 3 y 4).

En este laboratorio se reusarán **obligatoriamente** los componentes ya implementados en los laboratorios de clasificación y regresión y en el de optimización. El problema consiste en predecir las 24 horas siguientes de la serie temporal proporcionada (FH=24) mediante los siguientes ejercicios:

1. Construya una clase **FactoriaSerieTemporal** que lea un fichero Excel como el que se proporciona y genere un *DataSet de Regresión* (ver Laboratorio 2). El método que lea debe tener como parámetro PH que servirá para determinar el número de columnas o variables lags del *DataSet*, no olvide añadir el valor para el resultado esperado. Es decir, el *DataSetRegresión* tendrá PH+1 columnas (PH variables (lags) más el valor esperado).
2. Aplique la recta de regresión como modelo para predecir el siguiente valor. Para entrenar la recta NO USE toda la serie temporal porque tardaría demasiado tiempo, por ejemplo, entrene con los últimos 1000 registros (unos 40 días). Haga que el valor predicho se introduzca de nuevo en el modelo y así mediante una “*ventana deslizante*” se predigan el resto de los valores hasta 24.
3. Implemente seis versiones de la recta de regresión modificando PH, la tasa de aprendizaje, sin normalización, con normalización min-max o z-score. Tenga en cuenta que la tasa de aprendizaje sin normalización deberá ser más pequeña que con normalización (pregunte a la IA por qué). Recuerde que si hace normalización debe ajustar el valor predicho al rango original antes de hallar el error para que los MAEs sean



comparables. Quédese con el mejor resultado de MAE como base para los siguientes experimentos.

4. Pruebe ahora el regresor kNN usando la distancia euclídea ponderada. En primer lugar, y como comparación base use como pesos la correlación entre cada lag y el resultado esperado. Varie el PH (por ejemplo 6, 12, 24 y 48) y el k (por ejemplo 1, 3, 5) para hacer distintas pruebas. Apunte el mejor resultado de MAE.
5. Siguiendo con el regresor kNN en este ejercicio se van a optimizar los pesos de la distancia ponderada mediante una heurística de optimización como las vistas en los laboratorios 7 u 8. Esto implica hacer un proceso de entrenamiento más complejo ya que para cada paso del optimizador la función a minimizar es el MAE, lo que implica aplicar el regresor kNN al conjunto de datos de entrenamiento. Es decir, la función a minimizar es el MAE del regresor kNN usando la distancia ponderada. Escoja el mejor PH del ejercicio 5 y pruebe $k=1, 3, 5$ usando como optimizador el algoritmo que mejores resultados le dio en la práctica 7.

NOTA: Se le proporciona un fichero Excel con la ST completa, aunque realmente solo va a entrenar con los últimos 1000 valores. Pero por si en casa quiere probar con más valores y comprobar si las predicciones mejoran al ampliar el conjunto de train. En el Excel de test tiene dos días, aunque solo se le pide predecir 24 horas, también por si quiere ampliar el FH en casa. Recuerde que debe separar completamente la fase de train de la de test. Es decir, para entrenar los modelos (recta de regresión o kNN con distancia ponderada) solo debe usar los datos hasta el 28 de diciembre inclusive. Los resultados de MAE los debe presentar sobre los valores del 29 de diciembre.

Cuando termine presente un fichero de texto (Word, Excel o lo que prefiera) con al menos los siguientes resultados:

Recta de regresión (MAE)

PH	Tasa	Min-Max?	Z-score?	MAE FH=24 (29/12/2026)
12	0,0001	No	No	
24	0,001	Sí	No	
...	...	...	...	
...	...	...	...	
...	...	...	...	
...	...	...	...	



kNN ponderado con correlación

PH (6, 12, 24, 48)	K (1, 3, 5)	MAE FH=24 (29/12/2026)
6	1	
6	3	
6	5	
12	1	
12	3	
...	...	
...	...	
...	...	

kNN con heurística

PH el mejor anterior	K (1, 3, 5)	MAE FH=24 (29/12/2026)
	1	
	3	
	5	

Guarde el código y el documento con las tablas de resultados en un zip y envíelo a su profesor de laboratorio al terminar la clase. No se aceptarán correos enviados después de las 19.40