

DÉCIMO LABORATORIO

En numerosas ocasiones cuando se trabaja con Series Temporales (ST), no se trabaja con los valores originales sino con los incrementos o decrementos de un valor al siguiente. Es decir, con la diferencia. De esta manera si tenemos la serie temporal $\{x_1, x_2, x_3, x_4, \dots, x_t, x_{t+1}, \dots\}$ la convertimos en la serie $\{y_1, y_2, y_3, y_4, \dots, y_t, y_{t+1}, \dots\}$ donde $y_t = x_t - x_{t-1}$.

Ejemplo: si tenemos la serie temporal 4, 3, 4, 2, 5, 7 ... se convierte en la serie -1, 1, -2, 3 (a cada elemento se le resta el anterior) y hay que guardar el valor primero (4) para poder reconstruir la serie original.

Primer Ejercicio


Vuelva a ejecutar los modelos de predicción del laboratorio anterior sobre la serie diferencias y compare si obtiene mejores resultados que los de la semana pasada. No olvide que para poder comparar los MAEs debe deshacer el cambio en la serie diferencias después de predecir. Esto es, si se tiene la serie diferencias del ejemplo anterior, y se quiere predecir el valor real que va después del 5 (es decir, el 7), al usar la serie diferencias se debe predecir el valor que va después del 3. Supongamos que sale 1, entonces el valor real predicho es 6 (puesto que estamos prediciendo el incremento o decremento entre elementos de la serie real, predecir 1 significa que se estima que la serie real se incrementa 1 sobre el último valor conocido que era 5), y, por tanto, el error es: 7 (valor real) – 6 (valor predicho) = 1.

Muestre en una tabla los mejores resultados obtenidos con la ST de diferencias en comparación con los de la semana pasada. ¿Hay algún modelo para el que funcione mejor trabajar con la serie diferencias?

Segundo Ejercicio

Otro problema clásico de ST donde se usan las series diferencias mejor que las series reales es la detección de anomalías. Una anomalía es un periodo de tiempo donde una serie ha tenido un comportamiento fuera de lo “normal”. Algunas veces las anomalías se pueden “ver” fácilmente solo representando la gráfica de la serie respecto al tiempo. Si se observan máximos o mínimos excesivos o periodicidades anómalas, posiblemente sea una anomalía. Desgraciadamente, en ocasiones, las anomalías no son sencillas de descubrir.

En este laboratorio se proporciona un fichero csv “reto_4_dias.csv” que contiene datos de sensórica recabados de un sistema de fabricación industrial en el que se miden 20 variables cada minuto. Cada variable mide valores físicos de temperatura, presión, velocidad, vibración, etc. durante 4 días completos. El primer día es el día “normal” con datos de laboratorio bajo condiciones óptimas que sirven para entrenar el modelo y los 3 días de datos a continuación son datos de días reales de operación del sistema en los que se quiere detectar las anomalías.



Para ello, vamos a recurrir al concepto matemático de correlación. En un sistema de producción en régimen normal las variables suelen estar correlacionadas (por ejemplo, a más velocidad más vibración). Si durante un periodo de tiempo “suficientemente largo” la vibración aumenta sin que lo haga la velocidad, la correlación se pierde, y se puede etiquetar como anomalía.

Se pide construir un proyecto Python que resuelva las siguientes funcionalidades:

1. Método que lea el fichero csv que se le proporciona, guardando los valores en una clase con una propiedad *datos* que sea un diccionario donde las claves sean los nombres de las variables y los valores listas de los datos de cada variable a lo largo del tiempo.
2. Método que represente gráficamente las ST originales para intentar descubrir anomalías. Como son 20 puede agruparlas de 4 en cuatro en cada gráfica.
3. Método que dada dos listas de valores calcule la correlación de Pearson de ambas.
4. Método tal que, dadas dos listas y un tamaño de ventana devuelva otra lista llamada **resultado** con las correlaciones de los valores de las dos listas mediante una “ventana deslizante”. Es decir, si la ventana vale 20, los primeros 19 valores de **resultado** no se calculan (se pueden poner a 1). El valor 20º (vigésimo) de **resultado** se calcula como la correlación de las dos listas, pero solo con los primeros 20 valores, el valor 21º con los valores de las listas entre la posición 2 y la 21, y así sucesivamente.
5. Un método que dada una lista de valores conteniendo una ST devuelva otra con sus diferencias.
6. Un método tal que dado un umbral y un objeto *datos* (como el leído del csv) y usando solo los valores de las variables del día 1 devuelva una lista de tuplas de nombres de variables que tienen correlación mayor que un determinado umbral (por defecto 0.8)
7. Un método que dado los valores de un día y la lista resultado del ejercicio 6 devuelva una lista con los minutos donde se ha producido una “ruptura” de la correlación (debe fijar un umbral, por ejemplo, por debajo de 0.1).
8. Construya un método tal que dada una lista como la que devuelve el ejercicio 7, agrupe los minutos en intervalos si la distancia entre dos minutos es menor que un umbral (por ejemplo 15). Con esto estamos agrupando las alarmas separadas por menos de 15 minutos. Debe devolver una lista de tuplas con intervalos de minutos. Filtre también los intervalos con una duración menor de otro umbral (por ejemplo 3 minutos). Es decir este método debe recibir dos umbrales como argumentos.
9. Con todo lo anterior ya debe estar todo listo para encontrar las anomalías escondidas en los días 2, 3 y 4. Haga un programa principal que invoque a los métodos anteriores y devuelva los intervalos de anomalías que se encuentran del sistema, señalando las variables que dan lugar a la anomalía. Cambie los umbrales del ejercicio 8 (los valores 15 y 3), para ver cómo varían los resultados.



10. Finalmente haga una representación gráfica de la ST de diferencias e intente ver si coinciden las anomalías que encuentra con la representación visual.

Entregue por correo electrónico en un fichero zip el código desarrollado en esta práctica (Ejercicios 1 y 2), los valores de MAE para la predicción de la ST de diferencias, las representaciones gráficas de las ST del fichero de anomalías (original y diferencias) y los intervalos de anomalías encontrados para distintos umbrales (por ejemplo, 0.15 y 0.0 para ruptura de correlación, 15 y 20 minutos para agrupación y 3 o 5 minutos para duración mínima).